Reporte Técnico de Actividades Práctico-Experimentales Nro. 003

1. Datos de Identificación del Estudiante y la Práctica

Nombre del estudiante(s)	Jaime Alejandro Landázuri Román Richard Ariel Chamba Sánchez Cael Alejandro Soto Cueva Domenica Nicole Rojas Pardo
Asignatura	Simulación
Ciclo	5 A
Unidad	1
Resultado de aprendizaje de la unidad	R1. Aplica análisis estadísticos de los datos de la Simulación para mejorar la calidad de los resultados, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	003
Título de la Práctica	Simulación de un sistema de líneas de espera M/M/1 mediante SimPy
Nombre del Docente	José O. Guamán Q.
Fecha	15 de Octubre de 2026 16 de Octubre 2026
Horario	Jueves 10h30 a 11h30 Viernes 07h30 a 09h30
Lugar	Aula
Tiempo planificado en el Sílabo	3 horas

2. Objetivo(s) de la Práctica

Simular un sistema de líneas de espera M/M/1 utilizando Python y SimPy, analizando el comportamiento de los clientes, la cola y el servidor.

1. Implementar un modelo M/M/1 utilizando la biblioteca SimPy.
2. Calcular las principales métricas teóricas del sistema de espera.
3. Comparar los resultados teóricos con los obtenidos mediante la simulación.

3. Materiales y reactivos

- Python 3.x.
- Biblioteca SimPy.
- NumPy.
- Matplotlib.
- Editor de código: Visual Studio Code, PyCharm o Jupyter Notebook.

4. Equipos y herramientas

- Computador.
- Procesador de 2 núcleos o superior.
- Mínimo 4 GB de RAM.
- Sistema operativo Linux o macOS.

5. Procedimiento / Metodología Ejecutada

5.1. Fundamento teórico

El modelo **M/M/1** representa un sistema de líneas de espera con llegadas de clientes siguiendo una distribución de Poisson, tiempos de servicio con distribución exponencial, un único servidor y atención de clientes bajo el principio FIFO (*primero en llegar, primero en ser atendido*).

El modelo utiliza dos parámetros principales:

- λ: tasa promedio de llegada de clientes.
- μ: tasa promedio de servicio del servidor.

La utilización del servidor se calcula mediante:

$$\rho = \frac{\lambda}{\mu}$$

Nota sobre una errata de la guía. La guía de la práctica (ğ5.1) imprime $\rho = \mu/\lambda$, lo que contradice su propia condición de estabilidad $\lambda < \mu$ expresada unas líneas más abajo y también su pseudocódigo, que usa $\rho = \lambda/\mu$. Con la fórmula impresa, los tres escenarios de la guía darían $\rho = 1{,}50$, $1{,}20$ y $1{,}03$, es decir un servidor saturado en los tres casos, y las medidas L, L_q, W y W_q no existirían (solo están definidas para $\rho < 1$). Este informe usa la definición correcta $\rho = \lambda/\mu$, que es además la que aparece en la bibliografía de teoría de colas.

Para que el sistema sea estable debe cumplirse:

$$\lambda < \mu$$

Las principales medidas teóricas del sistema son:

$$L = \frac{\lambda}{\mu - \lambda} \qquad L_q = \frac{\lambda^2}{\mu(\mu - \lambda)}$$

$$W = \frac{1}{\mu - \lambda} \qquad W_q = \frac{\lambda}{\mu(\mu - \lambda)}$$

5.2. Escenarios ejecutados

Se ejecutaron los tres escenarios indicados por la guía, todos con $\mu = 3{,}0$:

Símbolo	Significado
λ	Tasa de llegada de clientes
μ	Tasa de servicio
ρ	Utilización del servidor
L	Número promedio de clientes en el sistema
L_q	Número promedio de clientes en la cola
W	Tiempo promedio en el sistema
W_q	Tiempo promedio de espera en la cola

Cuadro 1: Notación empleada.

Escenario	λ	μ	Condición
1	2,0	3,0	Sistema estable
2	2,5	3,0	Mayor utilización
3	2,9	3,0	Cerca de saturación

Cuadro 2: Escenarios de la guía. La utilización teórica resulta $\rho = 0{,}667$, $0{,}833$ y $0{,}967$ respectivamente.

5.3. Implementación

El programa se desarrolló en Python siguiendo el pseudocódigo de la guía y se estructuró en tres capas (modelo, vista y controlador) para que cada medida tuviera un único responsable en el código. Los componentes principales son:

- **Motor de simulación** (`model/simulation.py`): crea un entorno SimPy con un servidor de `capacity = 1`, genera los clientes con tiempos entre llegadas exponenciales de tasa λ, los atiende en orden FIFO con tiempos de servicio exponenciales de tasa μ y registra, por cada cliente, el instante de llegada, el inicio y fin de servicio, el tiempo de espera y el tiempo de servicio. El estado del sistema se guarda en un registro inmutable por cliente y en una traza de la longitud de la cola a lo largo del tiempo.
- **Métricas teóricas** (`model/metrics.py`): implementa las fórmulas del apartado anterior y actúa como *oráculo* de correctitud del simulador.
- **Análisis** (`model/analysis.py`): agrupa las réplicas por escenario, calcula la media simulada, el intervalo de confianza al 95 % con la distribución t de Student y el error relativo de cada medida frente a la teoría.
- **Tabla y gráficas** (`view/`): exporta la tabla comparativa a CSV y LaTeX, y genera las figuras del informe.
- **Línea de comandos** (`controller/cli.py`): un solo comando reproduce todo el estudio:

```
python -m mm1 --scenarios --replications 30 --sim-time 1000 --out outputs/
```

Parámetros de la corrida oficial. 30 réplicas por escenario, sim_time $= 1000$ unidades de tiempo y semilla base 42, de la cual se derivan de forma determinista las semillas

de cada réplica. En total se ejecutaron **90 simulaciones**. La corrida es **reproducible**: repetir el comando produce exactamente los mismos números.

Justificación del número de réplicas. Una sola corrida no es evidencia suficiente cuando el sistema está cerca de la saturación: con $\rho = 0{,}967$ el tiempo de espera tiene una distribución de cola pesada y una corrida individual puede desviarse hasta un 74 % de la teoría sin que el simulador esté equivocado. Por eso se promedian 30 réplicas independientes por escenario y se reporta el intervalo de confianza, que es lo que permite afirmar si la teoría queda o no dentro del rango de lo simulado.

6. Resultados

6.1. Comparación entre resultados teóricos y simulados

La Tabla 3 presenta, para cada escenario, los valores teóricos obtenidos con las fórmulas del modelo y los valores simulados obtenidos como promedio de las 30 réplicas.

Esc.	λ	ρ	L	L_q	W	W_q	Espera simulada	Cola simulada
1	2,0	0,6667	2,0000	1,3333	1,0000	0,6667	**0,6885**	**1,3921**
2	2,5	0,8333	5,0000	4,1667	2,0000	1,6667	**1,6211**	**4,0694**
3	2,9	0,9667	29,0000	28,0333	10,0000	9,6667	**8,5078**	**24,7945**

Cuadro 3: Comparación de resultados teóricos y simulados por escenario. Las columnas ρ, L, L_q, W y W_q son teóricas; las dos últimas son los promedios simulados de 30 réplicas.

6.2. Intervalo de confianza y error relativo

La Tabla 4 reporta el intervalo de confianza al 95 % de la espera media simulada y el error relativo de cada medida respecto de su valor teórico. El intervalo se calculó con la distribución t de Student sobre las 30 medias por réplica, que es la cantidad que se compara contra la teoría y no la dispersión de clientes individuales.

Esc.	Desv. est.	IC 95 % de la espera	¿Contiene al teórico?	Err. L	Err. L_q	Err. W_q
1	0,0983	$[0{,}6518;\ 0{,}7252]$	Sí (0,6667)	3,19 %	4,41 %	3,28 %
2	0,3898	$[1{,}4755;\ 1{,}7666]$	Sí (1,6667)	2,12 %	2,33 %	2,73 %
3	8,2631	$[5{,}4223;\ 11{,}5933]$	Sí (9,6667)	12,69 %	11,55 %	11,99 %

Cuadro 4: Intervalo de confianza al 95 % de la espera media simulada y error relativo por medida. En los tres escenarios el valor teórico queda *dentro* del intervalo simulado.

Hallazgo principal. En los **tres** escenarios el valor teórico de W_q cae dentro del intervalo de confianza al 95 % construido con las réplicas simuladas. Esto significa que el simulador es estadísticamente consistente con el modelo analítico: las diferencias observadas son compatibles con el error de muestreo y no con un sesgo de implementación.

6.3. Gráficas

La Figura 1 compara teoría y simulación para las cuatro medidas en los tres escenarios; el panel de W_q incluye el intervalo de confianza como barra de error.

La Figura 2 muestra el crecimiento de la espera y de la cola en función de la utilización ρ.

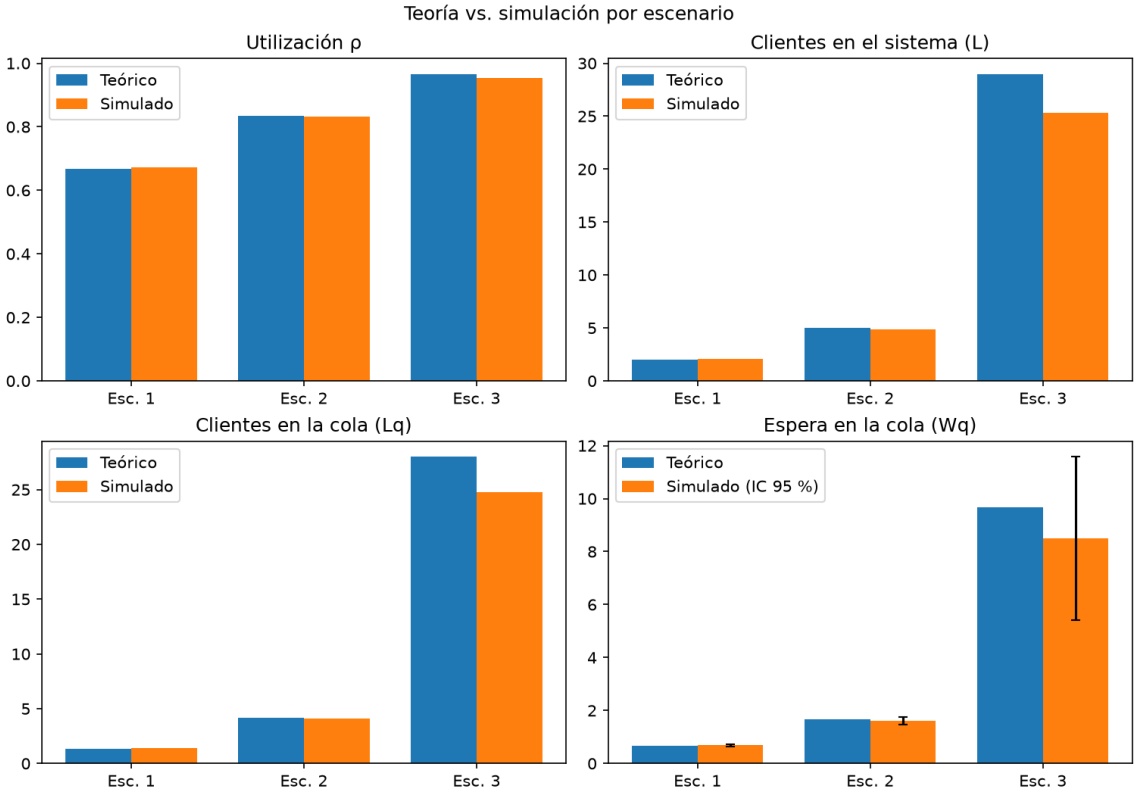


Figura 1: Comparación teoría vs. simulación por escenario. El intervalo de confianza del panel W_q es ancho en el escenario 3 porque $\rho \to 1$: la espera se vuelve muy variable, pero la teoría sigue dentro del rango.

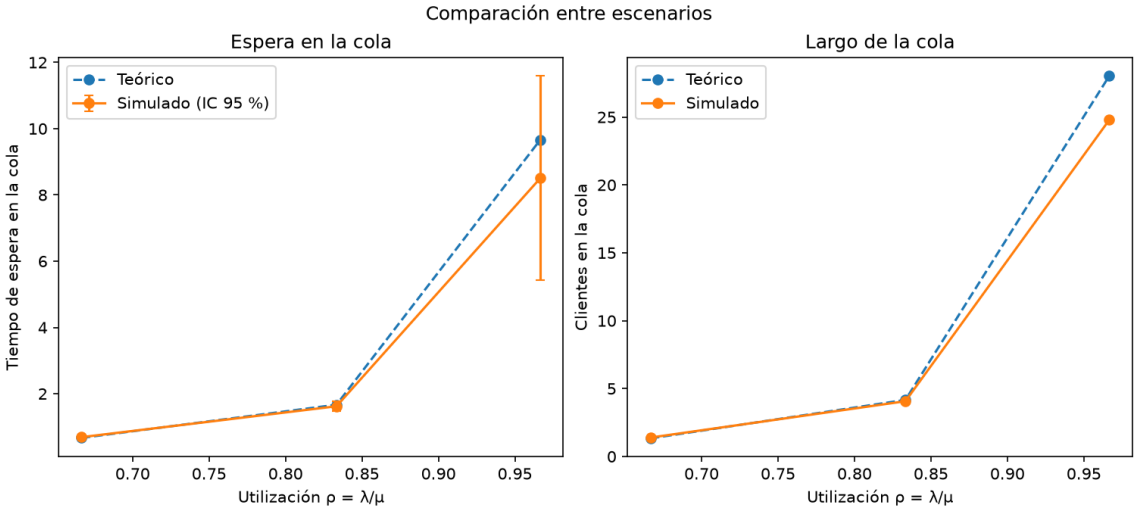


Figura 2: Espera en la cola y largo de la cola en función de ρ. El crecimiento es marcadamente no lineal: al pasar de $\rho = 0{,}667$ a $\rho = 0{,}967$, la espera simulada crece más de doce veces.

La Figura 3 muestra la evolución temporal de la cola y los tiempos de espera de cada cliente en el escenario más exigente.

Las figuras equivalentes de los escenarios 1 y 2 están en `reports/figures/` y se regeneran con el mismo comando.

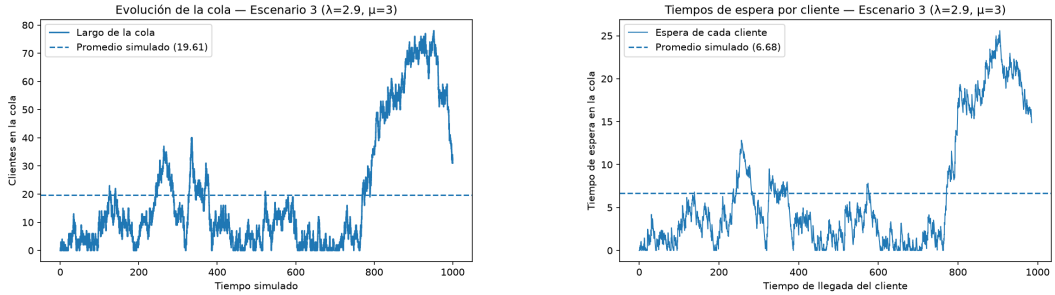


Figura 3: Escenario 3 ($\lambda = 2{,}9$, $\rho = 0{,}967$): evolución de la cola y tiempos de espera por cliente. La cola alcanza valores altos de forma sostenida y los tiempos de espera presentan una dispersión mucho mayor que en los escenarios 1 y 2.

7. Análisis de Resultados

7.1. Comportamiento del sistema según la guía

La guía anticipa que *cuando λ se aproxima a μ, aumentan el tiempo de espera y el tamaño de la cola, debido a que el servidor trabaja cerca de su capacidad máxima*. Los resultados confirman ese comportamiento en las dos direcciones:

- La utilización teórica crece de $0{,}667$ a $0{,}833$ y luego a $0{,}967$, y la utilización *medida* en la simulación la acompaña ($0{,}673$, $0{,}833$ y $0{,}953$).
- El tiempo de espera simulado pasa de $0{,}69$ a $1{,}62$ y luego a $8{,}51$ unidades, es decir un factor de más de doce entre el primer y el último escenario. La cola promedio simulada pasa de $1{,}39$ a $4{,}07$ y luego a $24{,}79$ clientes.

El crecimiento no es lineal sino acelerado: pasar de $\rho = 0{,}667$ a $\rho = 0{,}833$ casi duplica la espera, mientras que pasar de $\rho = 0{,}833$ a $\rho = 0{,}967$ la multiplica por más de cinco. Esto es exactamente lo que predicen las fórmulas, donde W_q diverge cuando $\lambda \to \mu$.

7.2. Por qué lo simulado no coincide exactamente con lo teórico

Esta es la pregunta de control número 9 y merece una respuesta medida en lugar de una explicación genérica. Hay cuatro razones, y las cuantificamos con nuestros datos.

1. **La teoría describe el largo plazo; la simulación mide una muestra.** Las fórmulas L, L_q, W y W_q son los valores esperados del sistema en estado estacionario, es decir el límite cuando el tiempo simulado tiende a infinito. Una corrida de duración finita devuelve una estimación con varianza.
2. **El error disminuye al alargar la corrida.** Repitiendo el escenario 1 con horizontes crecientes, el error relativo de W_q baja de $12{,}9$ % con sim_time $= 500$ a $5{,}7$ % con 2000, $2{,}5$ % con $10\,000$ y $1{,}6$ % con $50\,000$. Que el error tienda a cero al aumentar la muestra es la firma de un estimador *consistente*: el simulador converge a la teoría, no se desvía de ella.
3. **Cerca de la saturación la varianza explota.** Este es el punto más importante y el que explica la diferencia entre el escenario 3 y los otros dos. Con $\rho = 0{,}967$ el tiempo de espera tiene una distribución de *cola pesada*: la mayoría de los clientes espera poco, pero unos pocos esperan muchísimo, y esos pocos casos arrastran

el promedio de toda la corrida. Una corrida individual de ese escenario puede desviarse hasta un 74 % de la teoría, y sin embargo la media de 30 réplicas se reduce a un 12 % y el intervalo de confianza contiene al valor teórico. La desviación grande de una corrida aislada **no es un error del simulador**: es la naturaleza del sistema cerca de la saturación.

4. **La ley de Little se cumple en los resultados simulados.** Como comprobación interna independiente de las fórmulas del modelo, verificamos $L = \lambda \cdot W$ sobre las salidas de la simulación: el desvío es inferior al $0{,}9$ % en los tres escenarios. Si el registro de tiempos o el orden FIFO estuvieran mal implementados, esta relación no se cumpliría.

Por todo lo anterior, el procedimiento correcto no es comparar una corrida contra la teoría, sino comparar **el promedio de varias réplicas** y verificar si la teoría cae dentro del intervalo de confianza. Eso es lo que hace la Tabla 4, y el resultado es que cae en los tres casos.

8. Preguntas de Control

1. **¿Qué representa el modelo M/M/1?** Es un sistema de líneas de espera con un único servidor. La notación de Kendall describe sus tres características: la primera *M* indica que las llegadas siguen un proceso de Poisson (tiempos entre llegadas exponenciales), la segunda *M* que los tiempos de servicio son exponenciales, y el *1* que hay un solo servidor. Los clientes se atienden en orden FIFO. En este trabajo los tres escenarios son M/M/1 con $\mu = 3{,}0$ y λ creciente.

2. **¿Qué representan λ y μ?** λ es la tasa promedio de llegada: la cantidad de clientes que llegan por unidad de tiempo. μ es la tasa promedio de servicio: la cantidad de clientes que el servidor puede atender por unidad de tiempo si nunca le falta trabajo. Sus recíprocos son los tiempos promedio: $1/\lambda$ es el tiempo medio entre llegadas y $1/\mu$ el tiempo medio de servicio. Con $\mu = 3{,}0$ el servicio promedio dura $1/3$ de unidad de tiempo; con $\lambda = 2{,}0$ llega un cliente cada $0{,}5$ unidades en promedio.

3. **¿Por qué debe cumplirse $\lambda < \mu$ para que el sistema sea estable?** Porque la cola solo se vacía al ritmo al que el servidor atiende. Si llegan clientes más rápido de lo que se los puede atender, el trabajo pendiente se acumula sin límite y la cola crece indefinidamente. La condición equivale a $\rho = \lambda/\mu < 1$: el servidor debe tener capacidad sobrante. Si $\lambda \geq \mu$ el sistema no alcanza un estado estacionario y L, L_q, W y W_q no tienen valor finito. En el programa esta condición se verifica antes de simular y, si no se cumple, se informa `El sistema no es estable` sin ejecutar la simulación.

4. **¿Qué significa la utilización ρ?** Es la fracción del tiempo que el servidor está ocupado, $\rho = \lambda/\mu$. Su valor está entre 0 y 1 para un sistema estable. En la simulación se mide como el tiempo total de servicio efectivo dividido por el tiempo observado, y coincide con la teoría: $0{,}673$, $0{,}833$ y $0{,}953$ medidos contra $0{,}667$, $0{,}833$ y $0{,}967$ teóricos. Un ρ cercano a 1 indica un servidor casi saturado, y es ahí donde los tiempos de espera se disparan.

5. **¿Cuál es la diferencia entre W y W_q?** W es el tiempo total que un cliente permanece en el sistema, desde que llega hasta que termina de ser atendido. W_q es solo el tiempo que espera en la cola antes de que empiece su servicio. La relación es $W = W_q + 1/\mu$. En nuestros resultados del escenario 1: la espera simulada es $0{,}6885$ y el tiempo en el sistema es $1{,}0336$, y la diferencia $0{,}3451$ es aproximadamente $1/\mu = 0{,}3333$, el tiempo medio de servicio. La diferencia entre ambas medidas es constante: es el servicio, no la congestión.

6. **¿Cuál es la diferencia entre L y L_q?** L es la cantidad promedio de clientes en el sistema, contando tanto los que esperan como el que está siendo atendido. L_q cuenta solo los que esperan en la cola. La relación es $L = L_q + \rho$, porque el cliente en servicio aporta una fracción ρ del tiempo. En el escenario 1: $L = 2{,}0639$ y $L_q = 1{,}3921$, y la diferencia $0{,}6718$ coincide con la utilización medida $0{,}6732$: es el cliente que ocupa el servidor.

7. **¿Por qué SimPy utiliza una distribución exponencial para generar los tiempos?** Porque es la distribución que corresponde al supuesto de llegadas de Poisson. En un proceso de Poisson los tiempos *entre* eventos consecutivos se distribuyen exponencialmente, de modo que generar intervalos exponenciales es la forma de construir llegadas de Poisson. Además, la exponencial es la única distribución continua *sin memoria*: la probabilidad de que un cliente llegue en el próximo instante no depende de cuánto tiempo se lleva esperando desde la llegada anterior. Esa propiedad es lo que hace que el estado del sistema dependa solo de la cantidad de clientes presentes y no del historial, y es lo que permite deducir las fórmulas cerradas de L, L_q, W y W_q. Si los tiempos siguieran otra distribución, el modelo dejaría de ser M/M/1.

8. **¿Qué sucede con la cola cuando λ se aproxima a μ?** La cola y el tiempo de espera crecen de forma acelerada, no proporcional. Al acercarse λ a μ, ρ tiende a 1 y el denominador $\mu - \lambda$ de las fórmulas tiende a cero, de modo que L, L_q, W y W_q crecen sin límite. Nuestros datos lo muestran: la cola promedio simulada pasa de $1{,}39$ clientes con $\rho = 0{,}667$ a $4{,}07$ con $\rho = 0{,}833$ y a $24{,}79$ con $\rho = 0{,}967$, mientras la espera pasa de $0{,}69$ a $1{,}62$ y a $8{,}51$. El servidor trabaja casi todo el tiempo y cualquier ráfaga de llegadas se traduce directamente en cola.

9. **¿Por qué los resultados simulados pueden ser diferentes de los resultados teóricos?** Porque la teoría da el valor esperado en estado estacionario y la simulación mide una muestra finita, que tiene varianza. Verificamos tres hechos con nuestros datos: el error disminuye al alargar la corrida (de $12{,}9$ % a $1{,}6$ % al pasar de 500 a 50 000 unidades), la ley de Little se cumple sobre las salidas simuladas con menos de $0{,}9$ % de desvío, y el valor teórico cae *dentro* del intervalo de confianza al 95 % en los tres escenarios. Cerca de la saturación ($\rho = 0{,}967$) la dispersión es muy grande porque la espera tiene cola pesada: una corrida individual puede desviarse hasta un 74 % y aun así el modelo estar bien implementado. Por eso el informe compara promedios de 30 réplicas con su intervalo de confianza, y no corridas individuales.

10. **¿Qué ocurriría si λ fuera mayor que μ?** El sistema sería inestable: como llegan clientes más rápido de lo que se los atiende, el trabajo pendiente se acumula y la cola crece indefinidamente, sin alcanzar nunca un estado estacionario. ρ sería mayor que 1, lo que significa que el servidor necesitaría más tiempo de servicio del que dispone, y las medidas L, L_q, W y W_q no tendrían valor finito. El programa detecta esta situación y responde `El sistema no es estable` con un código de salida distinto de cero, sin ejecutar la simulación. Para atender esa demanda habría que agregar servidores (un modelo M/M/c) o aumentar la capacidad de servicio.

9. Conclusiones

1. *Sobre implementar un modelo M/M/1 con SimPy.* El sistema quedó implementado y funcionando: un servidor de capacidad 1, llegadas exponenciales, servicio exponencial, atención FIFO y registro por cliente. La simulación de los tres escenarios de la guía se reproduce con un solo comando, de forma determinista, gracias a que

las semillas se derivan de una semilla base. Se registran por cliente el instante de llegada, el inicio y fin de servicio, el tiempo de espera y el tiempo de servicio, y se conserva la traza temporal de la cola.

2. *Sobre calcular las métricas teóricas.* Las cinco medidas del modelo (ρ, L, L_q, W y W_q) quedaron implementadas según las fórmulas de la guía y se usaron como *oráculo* para verificar el simulador. Vale registrar que la guía imprime $\rho = \mu/\lambda$, incoherente con su propia condición de estabilidad; se usó la definición correcta $\rho = \lambda/\mu$, sin la cual los tres escenarios propios de la guía darían un servidor saturado y las demás métricas carecerían de valor.

3. *Sobre comparar teoría y simulación.* La comparación se hizo entre la teoría y el promedio de 30 réplicas por escenario, con su intervalo de confianza al 95 % y el error relativo de cada medida. El resultado central es que **en los tres escenarios el valor teórico cae dentro del intervalo simulado**, con errores relativos entre $2{,}1$ % y $12{,}7$ %. Queda además caracterizado el efecto que predice la guía: conforme λ se aproxima a μ, la utilización sube y tanto la espera como la cola crecen de forma acelerada, más de doce veces entre el primer y el último escenario. La principal limitación metodológica encontrada es que cerca de la saturación una corrida aislada no es evidencia suficiente y hay que reportar la incertidumbre; hacia allí apunta el uso del intervalo de confianza.

10. Demostración

El video de demostración muestra la ejecución del sistema desde la línea de comandos: la corrida de los tres escenarios, la generación de la tabla comparativa y de las figuras, y la animación de la evolución de la cola.

[PENDIENTE: enlace al video de demostración y a la animación (`cola.mp4`)]

11. Bibliografía

Referencias

[1] Donald Gross, John F. Shortle, James M. Thompson, and Carl M. Harris. *Fundamentals of Queueing Theory*. John Wiley and Sons, Hoboken, Nueva Jersey, 4 edition, 2008.

[2] José O. Guamán Q. *Guía de Actividades Práctico-Experimentales Nro. 003: Simulación de un sistema de líneas de espera M/M/1 mediante SimPy*. FEIRNNR, Carrera de Computación, Ecuador, 2026. Material de la asignatura Simulación, Unidad 1.

[3] Frederick S. Hillier and Gerald J. Lieberman. *Introduction to Operations Research*. McGraw-Hill Education, New York, 10 edition, 2015. Capítulo 17: Teoría de colas.

[4] Sheldon M. Ross. *Introduction to Probability Models*. Academic Press, Oxford, 11 edition, 2014. Procesos de Poisson y cadenas de Markov de tiempo continuo.

[5] Team SimPy. *SimPy: Discrete event simulation for Python*. SimPy, 2024. Documentación oficial de la biblioteca.